ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º 1

Consolidación de reportes de ventas - RetailAndina S.A.

Asignatura IDSD422 - Estadística y Programación para Ciencia de Datos I

Estudiante	Tabatha Peñaloza
Docente	Christian Suarez
Período académico	2026-B
Fecha de elaboración	19/10/2026
Entorno de trabajo	Visual Studio Code · Python y R
Repositorio (fork)	https://github.com/Tabatha-Orellana/IDSD422-lab1-lectura-datos

Resumen ejecutivo

Analicé los reportes semanales de RetailAndina S.A. en CSV, JSON y Excel mediante Python y R en Visual Studio Code. Los tres archivos contienen cinco registros y cuatro columnas con valores equivalentes. Se registraron 60.040 en ventas y 1.577 clientes; el ticket general fue 38,07. Guayaquil Centro lideró por sucursal y Sierra por región. Recomendé unificar esquemas y validar los datos antes de consolidar informes.

1. Introducción

El ERP de sucursales, la API de fidelización y el área de Finanzas entregan el mismo reporte en formatos distintos. La gerencia necesitaba comprobar su consistencia, verificar filas, columnas y tipos de datos, y obtener indicadores que ayudaran a interpretar las ventas de la semana 39.

2. Objetivos

General. Analizar y comparar los reportes de ventas en Python y R para comprobar la información y calcular indicadores comerciales.

- Leer los archivos CSV, JSON y Excel con herramientas adecuadas en ambos lenguajes.
- Inspeccionar dimensiones, columnas y tipos de datos, e identificar posibles inconsistencias.
- Calcular venta promedio por sucursal, ticket general y máximos por sucursal y región.
- Documentar el procedimiento y las salidas mediante scripts reproducibles y capturas propias.

3. Desarrollo de la práctica

3.1. Preparación y ejecución. Trabajé desde la raíz del fork en VS Code. Instalé pandas y openpyxl para Python; en R configuré Rscript y los paquetes readr, jsonlite y readxl. Completé los ocho scripts en **scripts/** y registré commits individuales.

3.2. Importación de datos. Los scripts leyeron archivos con rutas relativas. En Excel indiqué expresamente la hoja ventas. El JSON, compuesto por registros, se convirtió a una estructura tabular.

Fuente	Python	R	Resultado
CSV (ERP)	pd.read_csv()	readr::read_csv()	5 filas × 4 cols.
JSON (API)	json.load() + DataFrame	jsonlite::fromJSON()	5 filas × 4 cols.
Excel (Finanzas)	pd.read_excel()	readxl::read_excel()	5 filas × 4 cols.

Comprobación: las cuatro columnas fueron sucursal, region, ventas y clientes. Los valores y las dimensiones coinciden entre los tres archivos originales. Evidencias de lectura: figuras 1–3 y 6–8 en anexos.

3.3. Inspección de datos

En Python utilicé dtypes y en R str(). Las variables sucursal y region son texto; ventas y clientes son numéricas. Si estas últimas aparecieran como texto, revisaría caracteres, separadores y valores inconsistentes antes de realizar cálculos.

Columna	Python (CSV)	R (CSV)	Interpretación
sucursal	object	chr	Nombre de sucursal
region	object	chr	Región comercial
ventas	int64	dbl	Importe de ventas
clientes	int64	dbl	Conteo de clientes

3.4. Indicadores iniciales

Calculé la columna ticket = ventas / clientes y el ticket promedio general con ventas totales / clientes totales (60.040 / 1.577). Para las comparaciones agrupé las ventas por sucursal y región.

Indicador	Resultado
Venta promedio por sucursal	Quito Norte: 12.450 · Quito Sur: 9.870 Guayaquil Centro: 15.200 · Guayaquil Norte: 13.980 Cuenca: 8.540
Ticket promedio general	38,07
Mayor venta por sucursal	Guayaquil Centro — 15.200
Menor venta por sucursal	Cuenca — 8.540
Región con mayor venta	Sierra — 30.860

Como cada sucursal aparece en una sola fila, su media coincide con el importe registrado. Python y R arrojaron los mismos indicadores. Evidencias de inspección: figuras 4, 5, 9 y 10.

3.5. Respuestas a las preguntas

1. ¿Cuántas filas y columnas tiene cada formato? ¿Fue igual en los tres? ¿Por qué?
Cada formato tiene 5 filas y 4 columnas. Sí, porque contienen los mismos registros.

2. ¿Qué tipos se infirieron para ventas y clientes? ¿Qué indicaría que salieran como texto?
int64 en Python y dbl en R. Como texto indicarían posibles problemas de formato o datos no numéricos.

3. En Python, ¿qué devuelve json.load y por qué hay que “aplanarla”?
Devuelve una lista de diccionarios. Se convierte en DataFrame para organizar los registros en filas y columnas; los datos anidados deben normalizarse.

4. ¿Para qué sirve sheet_name/sheet al leer Excel?
Permite elegir la hoja de Excel que se leerá. En ambos lenguajes seleccioné ventas.

5. ¿Qué diferencia existe entre leer en Python y R?
Python utiliza DataFrames de pandas; R, data frames o tibbles. Ambos permiten el mismo análisis.

4. ¿Qué aprendí con esta práctica?

Aprendí a leer, inspeccionar y comparar archivos CSV, JSON y Excel usando Python y R. Comprendí que no basta con importar un archivo: también debo revisar su estructura, sus tipos de datos y la consistencia de sus valores antes de calcular indicadores. Practiqué la conversión de registros JSON a tablas y la selección explícita de una hoja de Excel.

Al principio Python no encontraba pandas y ejecuté scripts desde una carpeta equivocada. En R tuve dificultades para reconocer Rscript, instalar paquetes sin permisos administrativos y resolver una dependencia de readr. Comprobé rutas, configuré bibliotecas en mi carpeta personal y probé los programas individualmente. También aprendí a clonar mi fork: la carpeta extraída del ZIP no era un repositorio Git. Después trasladé los scripts y registré ocho commits separados.

En una próxima práctica prepararía primero los intérpretes, las dependencias, la ruta del proyecto y la conexión con GitHub. Esto habría evitado errores repetidos y facilitado un trabajo más reproducible.

5. Conclusiones y recomendación

- Verifiqué que CSV, JSON y Excel contenían los mismos 5 registros y 4 columnas, lo que permitió comparar los reportes sin alterar sus valores.
- El análisis arrojó 60.040 en ventas, 1.577 clientes y un ticket promedio de 38,07.
- Guayaquil Centro registró la mayor venta (15.200), Cuenca la menor (8.540) y Sierra lideró por región (30.860); los datos describen solo la semana analizada.

Recomendación para gerencia: estandarizar nombres y tipos de columnas, y verificar consistencia, datos faltantes y formato antes de automatizar la consolidación semanal.

6. Bibliografía y declaración de uso de IA

pandas development team. (s. f.). pandas.read_csv y pandas.read_excel. pandas Documentation. https://pandas.pydata.org/docs/

Wickham, H., Hester, J., y Bryan, J. (s. f.). readr. https://readr.tidyverse.org/

Ooms, J. (s. f.). jsonlite. https://cran.r-project.org/package=jsonlite

Escuela Politécnica Nacional. (2026). Laboratorio 1: Consolidación de reportes de ventas [Material de clase].

Declaración de IA: utilicé ChatGPT para explicar errores de configuración y apoyar la organización/redacción del informe. Ejecuté los scripts y realicé las capturas originales en VS Code.

7. Anexos - Evidencias (1-1)

Capturas tomadas de la ejecución real en Visual Studio Code. Se mantienen sin editar; las figuras 7 a 10 contienen las salidas capturadas en la terminal.

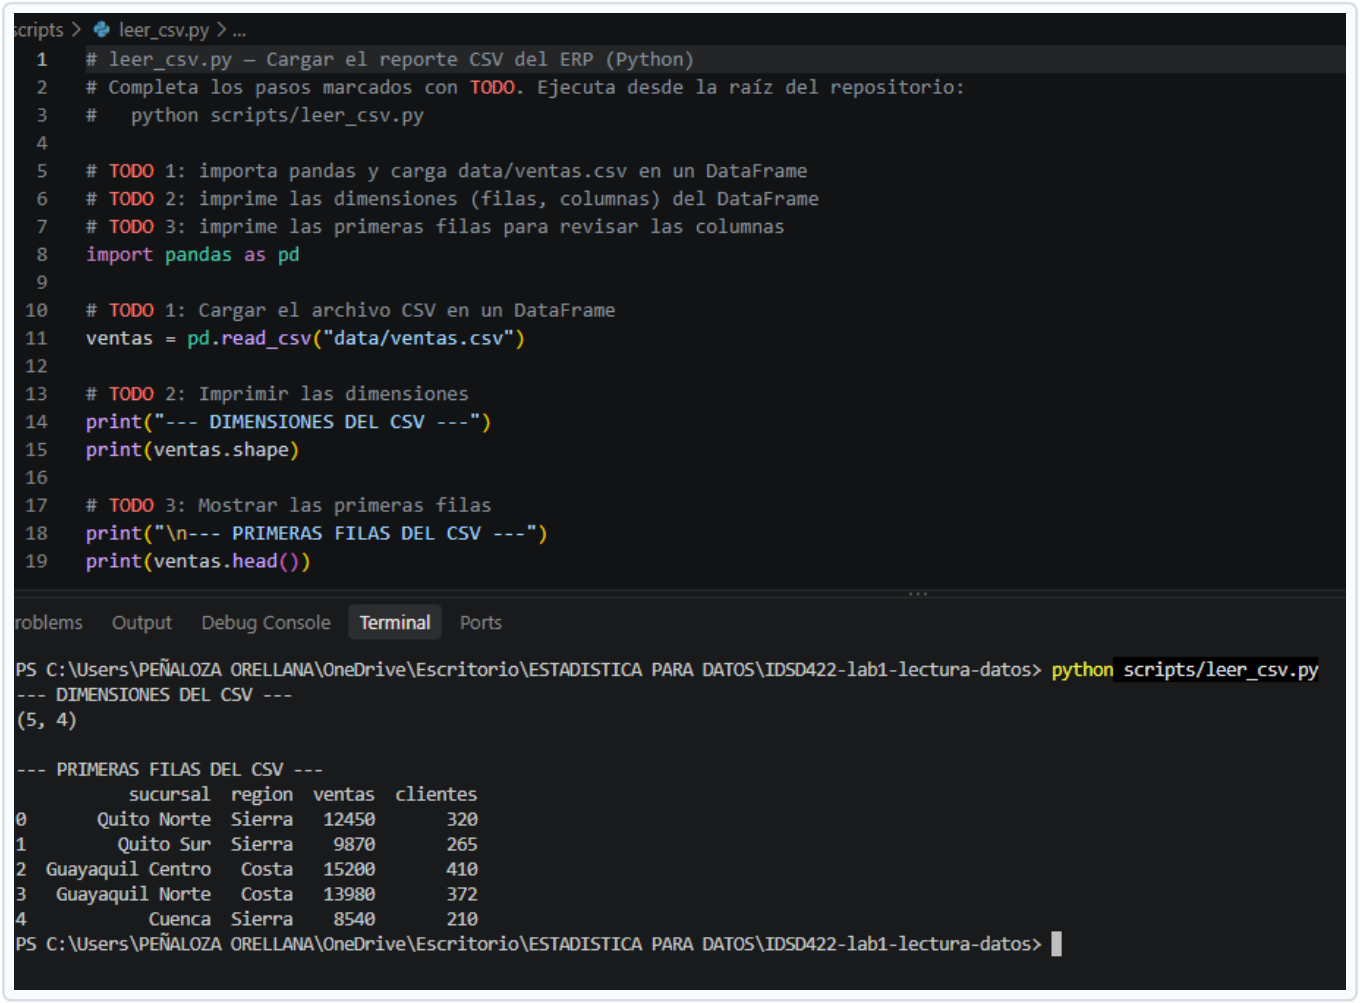


Figura 1. Lectura del archivo CSV en Python mediante pandas, obteniendo cinco filas y cuatro columnas.

7. Anexos - Evidencias (2-2)

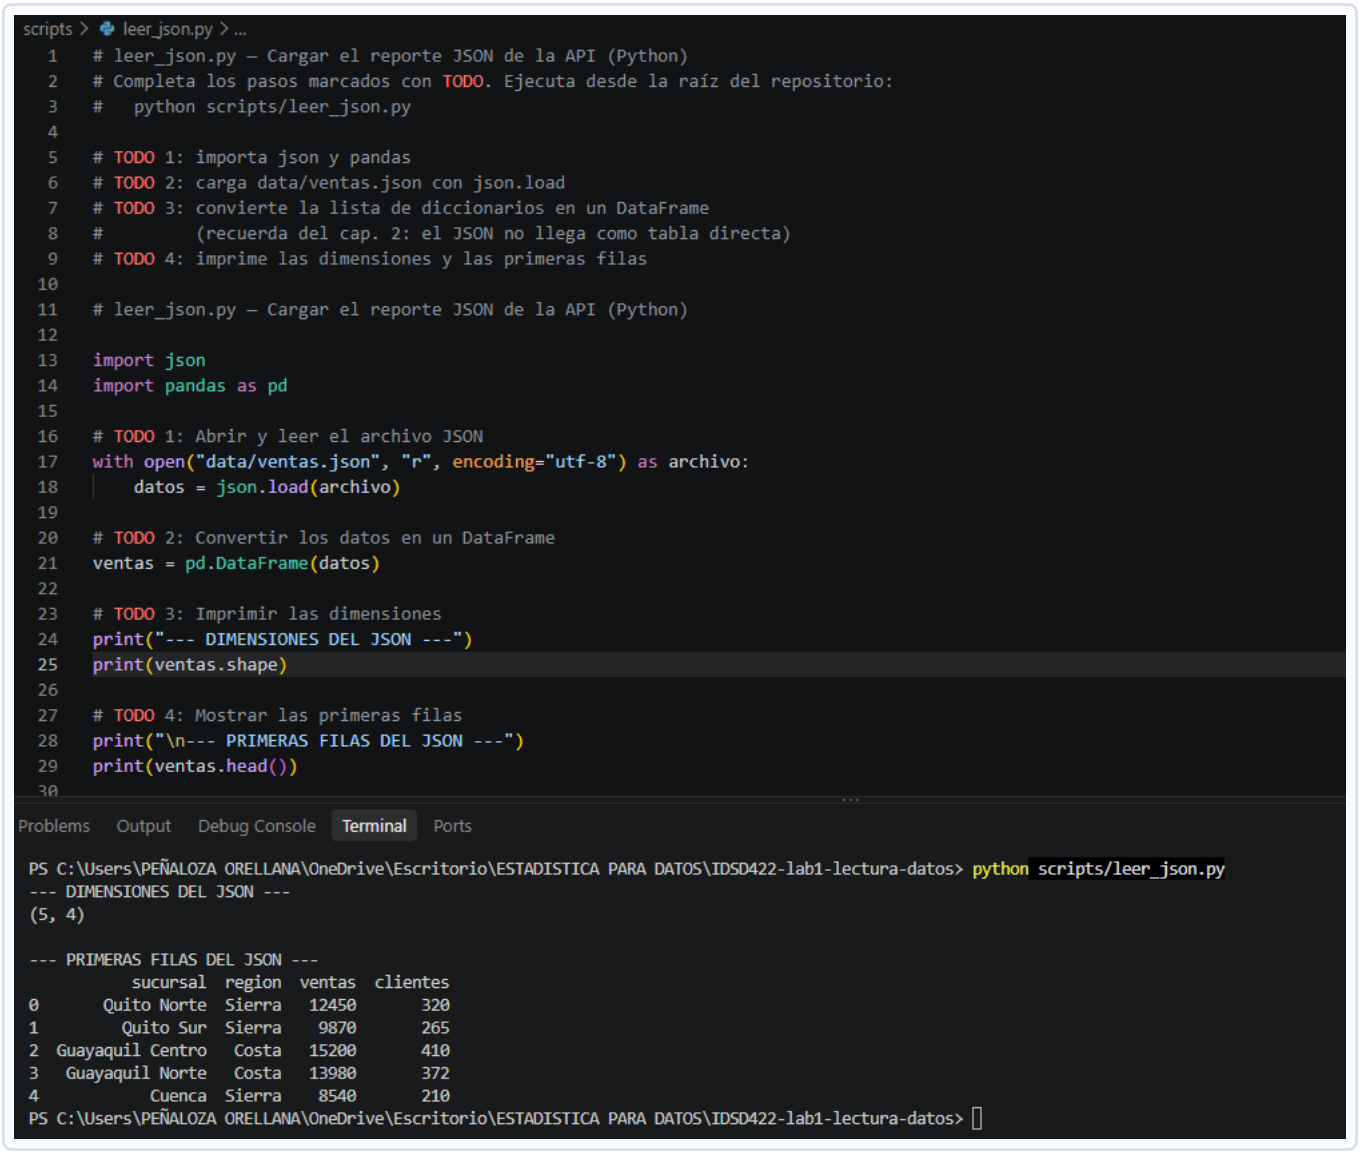


Figura 2. Lectura del JSON en Python y conversión de sus registros a un DataFrame.

7. Anexos - Evidencias (3-3)

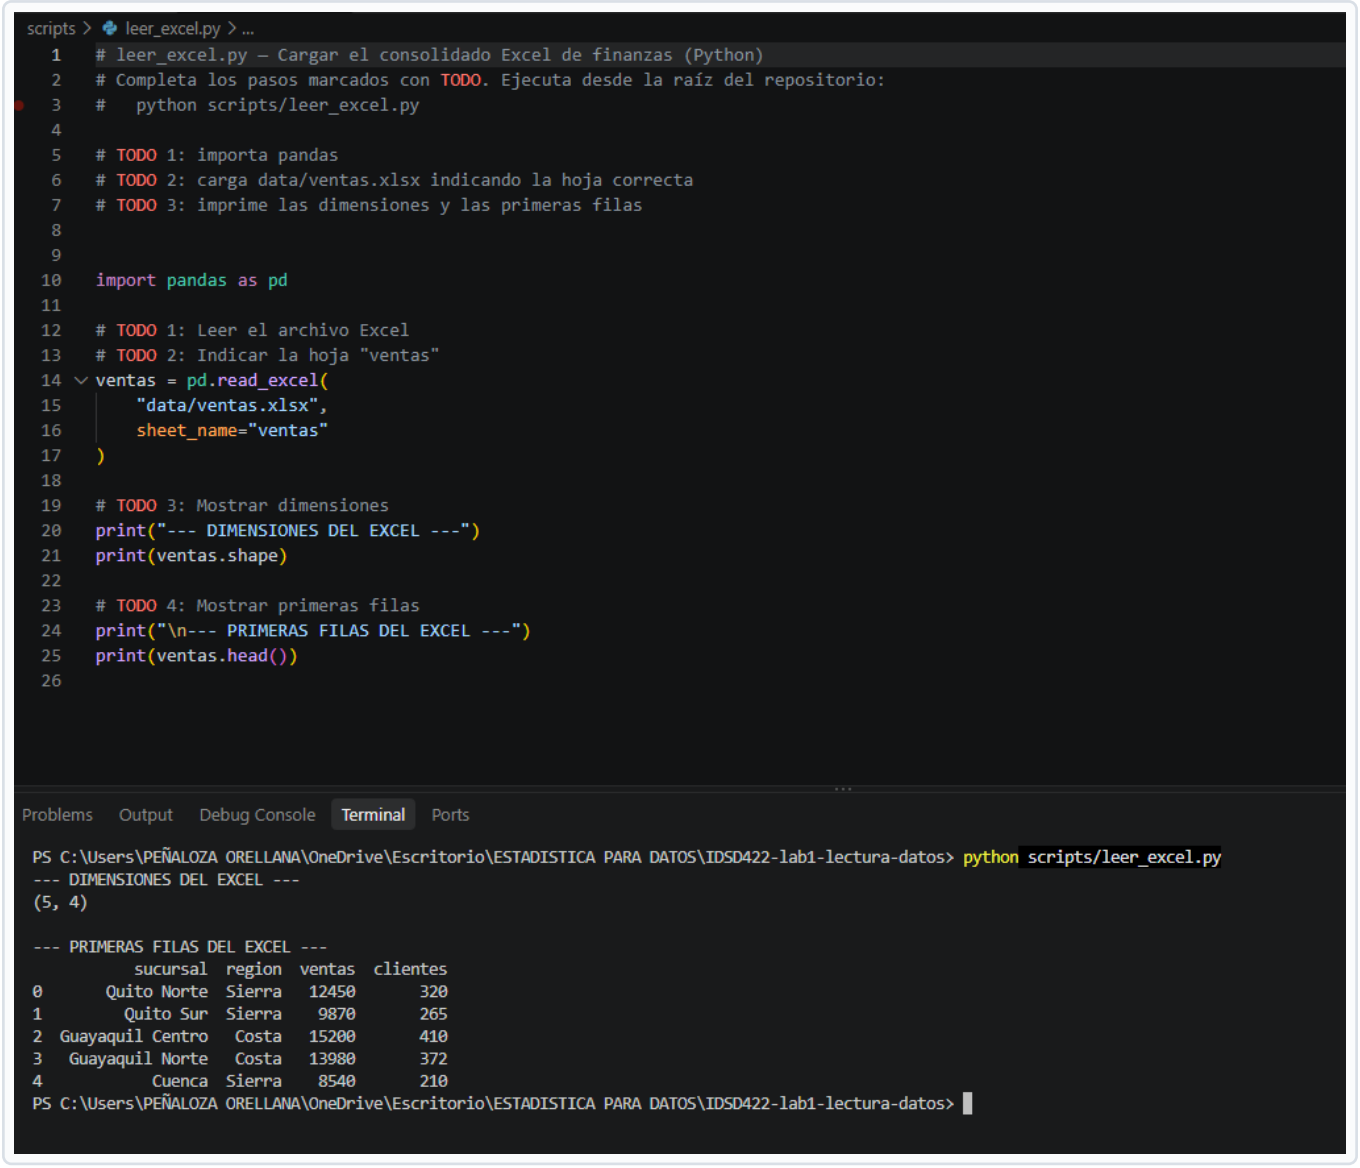


Figura 3. Lectura del Excel en Python, seleccionando la hoja ventas y comprobando dimensiones.

7. Anexos - Evidencias (4-4)

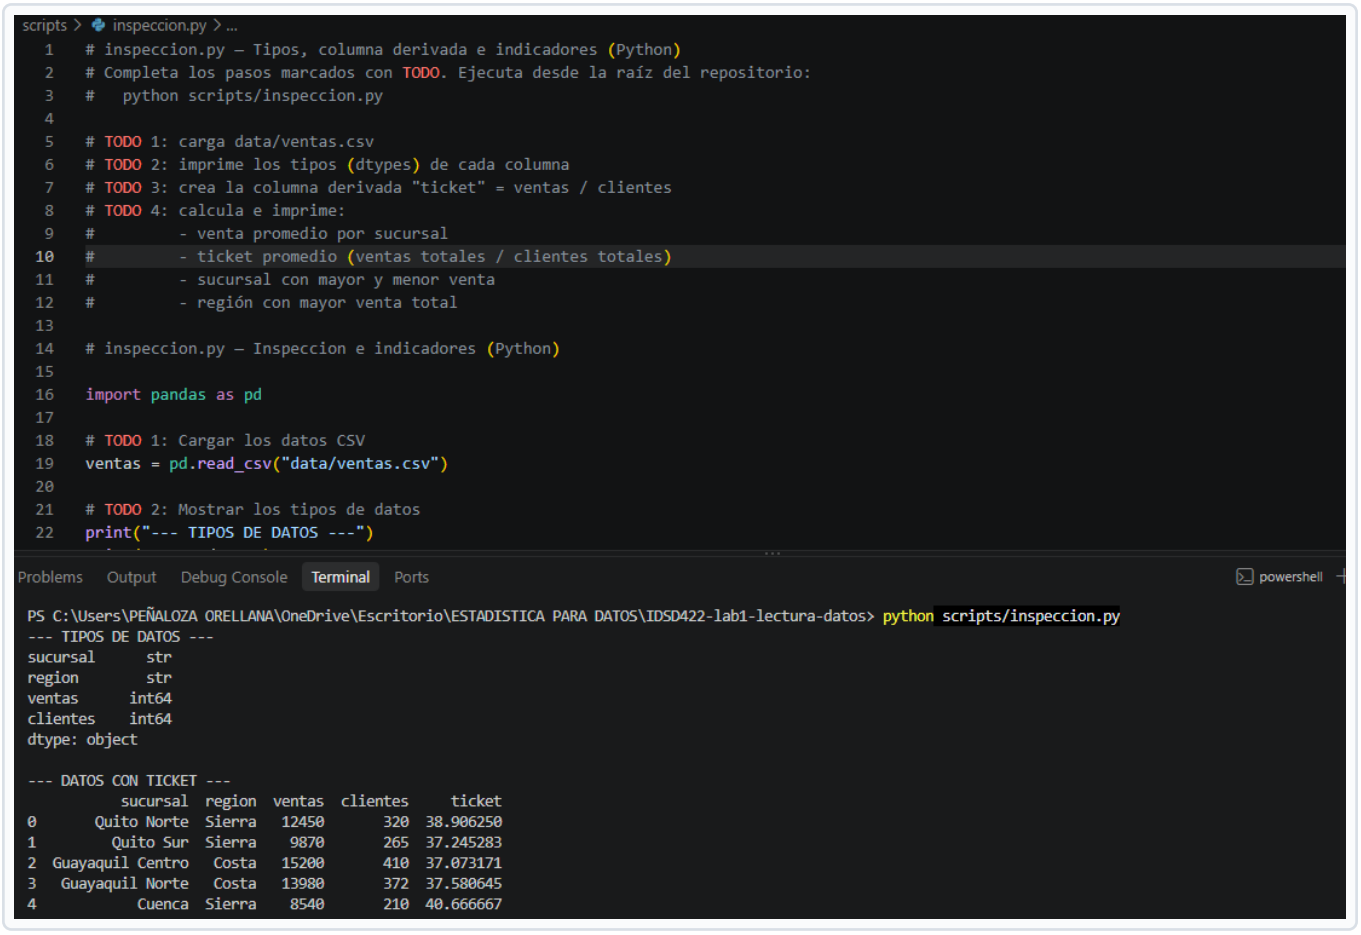


Figura 4. Inspección de tipos de datos y creación de la columna ticket en Python.

7. Anexos - Evidencias (5-6)

```
--- VENTA PROMEDIO POR SUCURSAL ---
sucursal
Cuenca              8540.0
Guayaquil Centro   15200.0
Guayaquil Norte    13980.0
Quito Norte        12450.0
Quito Sur           9870.0
Name: ventas, dtype: float64

--- TICKET PROMEDIO GENERAL ---
38.07

--- SUCURSAL CON MAYOR VENTA ---
Guayaquil Centro
15200

--- SUCURSAL CON MENOR VENTA ---
Cuenca
8540

--- REGION CON MAYOR VENTA ---
Sierra
30860
```

Figura 5. Cálculo de indicadores comerciales y ticket promedio general en Python.

```
scripts > leer_csv.R
# leer_csv.R — Cargar el reporte CSV del ERP (R)
# Completa los pasos marcados con TODO. Ejecuta desde la raíz del repositorio:
#   Rscript scripts/leer_csv.R

# TODO 1: carga data/ventas.csv con readr::read_csv en un data.frame
# TODO 2: imprime las dimensiones (dim) del data.frame
# TODO 3: imprime las primeras filas (head) para revisar las columnas

# leer_csv.R — Cargar el reporte CSV del ERP (R)

# TODO 1: Cargar data/ventas.csv con readr::read_csv()
ventas <- readr::read_csv(
  "data/ventas.csv",
  show_col_types = FALSE
)

Problems  Output  Debug Console  Terminal  Ports                powershell

PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\IDSD422-lab1-lectura-datos> $env:Path += ";C:\Program Files\R\R-4.6.1\bin"
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\IDSD422-lab1-lectura-datos> $env:R_LIBS_USER = "$HOME\R\library"
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\IDSD422-lab1-lectura-datos> Rscript --version
Rscript (R) version 4.6.1 (2026-06-24)
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\IDSD422-lab1-lectura-datos> Rscript scripts/leer_csv.R
--- DIMENSIONES DEL CSV ---
[1] 5 4

--- PRIMERAS FILAS DEL CSV ---
# A tibble: 5 × 4
  sucursal        region ventas clientes
  <chr>           <chr>   <dbl>    <dbl>
1 Quito Norte     Sierra  12450      320
2 Quito Sur       Sierra   9870      265
3 Guayaquil Centro Costa  15200      410
4 Guayaquil Norte  Costa  13980      372
5 Cuenca          Sierra   8540      210
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\IDSD422-lab1-lectura-datos>
```

Figura 6. Lectura del CSV con readr en R, comprobando cinco filas y cuatro columnas.

7. Anexos - Evidencias (7-8)

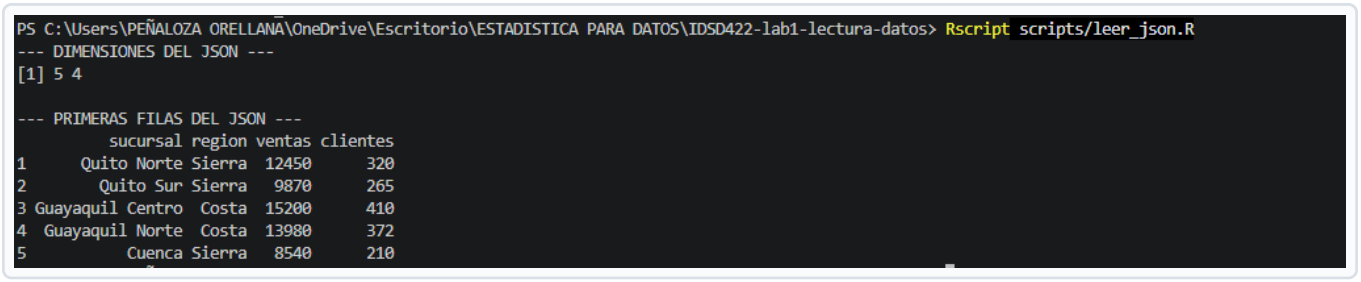


Figura 7. Lectura del JSON con jsonlite y conversión a data frame en R.

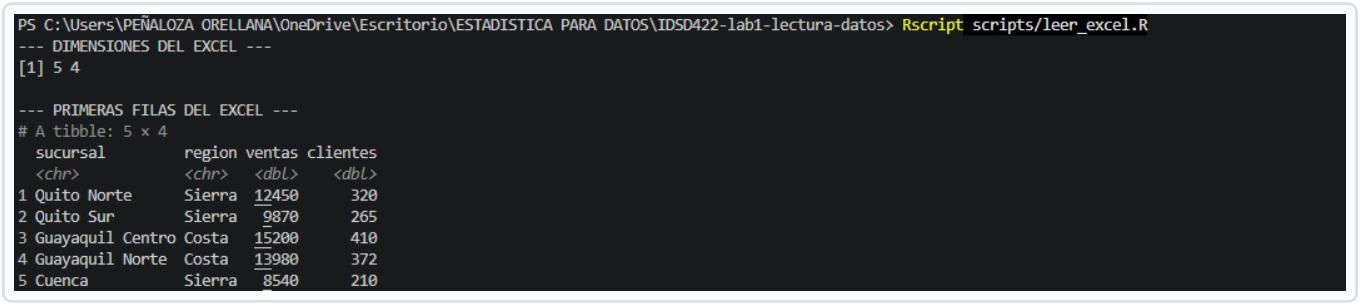


Figura 8. Lectura del Excel en R con readxl, seleccionando la hoja ventas.

7. Anexos - Evidencias (9-10)

```
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\IDSD422-lab1-lectura-datos> Rscript scripts/inspeccion.R
--- ESTRUCTURA Y TIPOS DE DATOS ---
spc_tbl_ [5 × 4] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ sucursal: chr [1:5] "Quito Norte" "Quito Sur" "Guayaquil Centro" "Guayaquil Norte" ...
 $ region  : chr [1:5] "Sierra" "Sierra" "Costa" "Costa" ...
 $ ventas  : num [1:5] 12450 9870 15200 13980 8540
 $ clientes: num [1:5] 320 265 410 372 210
 - attr(*, "spec")=
  .. cols(
  ..   sucursal = col_character(),
  ..   region = col_character(),
  ..   ventas = col_double(),
  ..   clientes = col_double()
  .. )
 - attr(*, "problems")=<pointer: 0x00000240c10ffdf0>

--- DATOS CON TICKET ---
# A tibble: 5 × 5
  sucursal         region ventas clientes ticket
  <chr>            <chr>   <dbl>    <dbl>  <dbl>
1 Quito Norte      Sierra  12450      320   38.9
2 Quito Sur        Sierra   9870      265   37.2
3 Guayaquil Centro Costa   15200      410   37.1
4 Guayaquil Norte  Costa   13980      372   37.6
5 Cuenca           Sierra   8540      210   40.7
```

Figura 9. Inspección de estructura y creación de la columna ticket en R.

```
--- VENTA PROMEDIO POR SUCURSAL ---
          sucursal venta_promedio
1           Cuenca           8540
2 Guayaquil Centro          15200
3  Guayaquil Norte          13980
4      Quito Norte          12450
5        Quito Sur           9870

--- TICKET PROMEDIO GENERAL ---
[1] 38.07

--- SUCURSAL CON MAYOR VENTA ---
          sucursal venta_total
2 Guayaquil Centro       15200

--- SUCURSAL CON MENOR VENTA ---
  sucursal venta_total
1   Cuenca        8540

--- REGION CON MAYOR VENTA ---
  region venta_total
2 Sierra       30860
```

Figura 10. Indicadores comerciales en R para contrastar los resultados de Python.